Laboratoire 3: Optimisation des programmes pour les DSP TMS320C6x

Le but de ce laboratoire est de se familiariser avec l'optimisation en assembleur sur la carte TMS320C6713. Il fait suite au cours et permet de rentrer concrètement dans le sujet. Code Composer Studio a été installé sur http://processors.wiki.ti.com/index.php/Download CCS et il s'agit de la version 5.2.1.00018.

Nous verrons différentes méthodes d'optimisation en 1^{ère} partie suivi de l'optimisation Pipeline en 2^{ème} partie.

I. Méthodes d'optimisation

Un programme qui marche n'est pas forcément le résultat final, il est souvent nécessaire d'optimiser son programme pour qu'il soit le plus performant possible. C'est le but de cette partie, on verra au total 4 programmes différents :

- 1. Non optimisé
- 2. Optimisation par parrallélisme ||
- 3. Optimisation des NOPs
- 4. Optimisation World Wide

Les temps de process seront ensuite analysés.

I.1 Non optimisé : sum1. asm

Il faut commencer par créer le « main », j'ai déclaré 2 tableaux short statiques x et y respectivement de taille 40, et ceci de façon globale. Ces tableaux sont initilialisés dans la boucle principale du programme.


J'ai décidé pour la suite de ne faire rentrer qu'un seul paramètre dans les fonctions, short n qui correspond à la taille des tableaux.

```
sum2.asm sum3.asm
main.c 🖾 🔝 sum1.asm
                                                🔊 sum4.asm
 2 * main.c
 3 */
 4 short sum1(short);
 5 short sum2(short);
 6 short sum3(short);
 7 short sum4(short);
 9 short x[40], h[40];
10
11 void main(void) {
12
13
      unsigned short i;
14
      short y = 0, n = 40;
15
16
      for(i=0; i<n; i++)</pre>
17
          x[i] = 2*i-1;
18
19
          h[i] = 40-i;
20
21
22
      y = sum1(n);
23
      y = sum2(n);
24
      y = sum3(n);
25
      y = sum4(n);
26
27 }
```

Pour accéder aux contenus des tableaux, j'utilise donc les variables globales. Là où cette méthode rajoute plus de cycles (comme nous le verrons par la suite), elle permet d'économiser du temps dans la transistion entre le $\mathcal C$ et l'assembleur. En effet car on ne fait rentrer qu'un seul paramètre n dans les fonctions.

```
S sum1.asm 
S sum2.asm S sum3.asm S sum4.asm
main.c
1
              .global _sum1
              .global _x
2
3
              .global h
4
                 .S _x,B0 ; Chargement de l adresse de la variable globale
5 sum1:
         MVKL
6
         MVKH
                 .S _x,B0
7
         MVKL
                 .S _h,A2 ; Chargement de l adresse de la variable globale
8
         MVKH
                 .S h,A2
9
         MV
                 .S A4,B2; B2 = n
10
                 .L A0; short y = 0
         zero
11
12 for:
         LDH
                 .D *B0++,B1; short x
                 .D *A2++,A3; short h
13
         LDH
14
         nop
15
         MPY
                 .M B1,A3,B1; B1 = x[i]*h[i]
16
         nop
17
         ADD
                 .L A0,B1,A0; y = y + x[i]*h[i]
18 [B2]
         SUB
                 .L B2,1,B2
                 .S for
19 [B2]
         В
20
         nop
                     5
                 .D A0,A4
21
         MV
                 .S2 B3
22
         В
23
                     5
         nop
```

En mode debug, j'ai commencé par vérifier les variables globales (les tableaux h et x), ainsi que le paramètre n=40 (dans le registre A4).




J'ai ensuite executé le programme pour vérifier la valeur de y qui doit être égal à 20500



1.2 Optimisation par parrallélisme : sum2. asm


La parrallélisation permet de faire travailler plusieurs unités de calcul en même temps. Lorsque l'on veut parralléliser les tâches, il faut bien définir les unités ainsi que leur numéro. Rajouter un « x » à la fin des unités indique que l'on fait un cheminement croisé, les opérandes de registre passent d'un côté à un autre.



J'en ai profité pour mettre en parrallèle les *MVK* nécessaires pour le chargement des variables globales.

```
S sum1.asm S sum2.asm S sum3.asm S sum4.asm
1
               .global _sum2
               .global _x
2
3
               .global _h
4
                           _x,B0 ; Chargement de l adresse de la variable globale
          MVKL
                   .S2
5_sum2:
                           _h,A2 ; Chargement de l adresse de la variable globale
6
      Ш
          MVKL
                   .S1
                           _x,B0
7
          MVKH
                   .S2
8
      Ш
          MVKH
                   .S1
                           h,A2
9
          MV
                   .S2x
                           A4,B2; B2 = n
                           A0 ; short y = 0
LØ
          zero
                   .L1
11
L2 for:
          LDH
                   .D2
                           *B0++,B1; short x
L3
          LDH
                   .D1
                           *A2++,A3 ; short h
L4
          nop
L5
          MPY
                   .M2
                           B1,A3,B1 ; B1 = x[i]*h[i]
L6
          nop
L7
          ADD
                   .L1
                           A0,B1,A0; y = y + x[i]*h[i]
L8 [B2]
          SUB
                   .L2
                           B2,1,B2
L9
   [B2]
                   .S1
                           for
20
          nop
21
          MV
                   .D1
                           A0,A4
22
                   .S2
                           В3
23
          nop
                           5
```

La procédure de debug est exactement la même que précedemment,




I.3 Optimisation des NOPs : sum3. asm


Pour cette partie, il faut bien analysé les temps de calcul de chaque instruction :

- Les opérations de calcul simples zero, ADD ou encore SUB prennent 1 cycle
- Les transferts simples MV, MVKL ou MVKH prennent 1 cycle
- Les opérations de multiplication terme à terme MPY prennent 2 cycles
- Les opérations de chargement LD prennent 5 cycles d'horloges du CPU
- Les branch B sont les plus coûteux et prennent 6 cyles

Le but est de réduire au minimum l'utilisation des NOP. On remarque par exemple que le temps que le branching se fasse, on a le temps d'executer des opérations.




Avec la même procédure de debug,



I.4 Optimisation World - Wide : sum4. asm

Dans cette optimisation, il est question de réduire le temps d'éxecution de la boucle principale. Pour cela on va utiliser des *LDW* au lieu de *LDH* qui permet de déplacer un mot de 32 bits en une seule fois. Voici l'idée générale de l'algorithme :



```
sum1.asm sum2.asm
                                  sum3.asm
                                                S sum4.asm ≅
1
              .global _sum4
              .global _x
2
3
              .global _h
4_sum4:
                  .S2
5
                           _x,B0 ; Chargement de l adresse de la variable globale
          MVKL
         MVKL
      _h,A2 ; Chargement de l adresse de la variable globale
                  .S1
6
7
          MVKH
                  .S2
                           _x,B0
8
      Ш
          MVKH
                  .S1
                           h,A2
9
          MV
                  .S2x
                           A4,B2; B2 = n
.0
                           Α0
          zero
                  .L1
.1
          zero
                  .L2
                           B7
.2
.3 for:
          LDW
                  .D2
                           *B0++,B1 ; double { h[i+1], h[i] }
                           *A2++,A3 ; double { x[i+1], x[i] }
          LDW
.4
                  .D1
                           B2,2,B2
.5
   [B2]
          SUB
                  .L2
.6 [B2]
          В
                  .S1
                           for
.7
          nop
                           2
.8
          MPY
                  .M2x
                           B1,A3,B5; B5 = x[i]*h[i]
.9
      | MPYH
                           B1,A3,A1; A1 = x[i+1]*h[i+1]
                  .M1x
10
          nop
                           A1,B7,B7; B7 = B7 + x[i+1]*h[i+1]
          ADD
!1
                  .L2x
12
      | ADD
                  .L1x
                           B5,A0,A0; A0 = A0 + x[i]*h[i]
!3
                  .S2
4
          В
                           В3
                           B7,A0,A0
15
          ADD
                  .L
16
          ΜV
                  .D1
                           A0,A4
17
          nop
                           3
```

Au début j'ai déroulé la boucle pour économiser des ressources au niveau de la gestion de la boucle. Mais il s'est avéré que le résultat n'est pas si significatif que ça par apport à la taille du programme (qui commence à deveir très gros). De plus ce déroulement n'est vraiment pas pratique si l'on veut changer la taille de la boucle (il faut recopier le code à chaque fois..). Au final même en enlevant le branch *B*, les *LD* au début prennent du temps à se finir donc on ne gagne pas là-dessus. On gagne au total 2 cyles d'instructions par rapport à une optimisation world wide « normale » ce qui ne vaut vraiment pas le coup.

1.5 Mesure de performances

J'ai mesuré les performances en mode Debug et Release. Le premier taleau correspond à la mesure de performance lorsque l'on lance le programme pour la première fois :

1									
Name	Calls	Excl Count Min	Excl Count Max	Excl Count Average	Excl Count Total	Incl Count Min	Incl Count Max	Incl Count Average	Incl Count Total
main()	1	-	-	1419.00	1419	-	-	3224.00	3224
sum1	1	684	684	684.00	684	684	684	684.00	684
sum2	1	621	621	621.00	621	621	621	621.00	621
sum3	1	330	330	330.00	330	330	330	330.00	330
sum4	1	170	170	170.00	170	170	170	170.00	170

Name	Calls	Excl Count Min	Excl Count Max	Excl Count Average	Excl Count Total	Incl Count Min	Incl Count Max	Incl Count Average	Incl Count Total
main()	1	1459	1459	1459.00	1459	3223	3223	3223.00	3223
sum1	1	653	653	653.00	653	653	653	653.00	653
sum2	1	611	611	611.00	611	611	611	611.00	611
sum3	1	330	330	330.00	330	330	330	330.00	330
sum4	1	170	170	170.00	170	170	170	170.00	170

Ainsi l'optimisation World Wide permet de diviser par plus de 3 le nombre de cycles!

Mode Release

Name	Calls	Excl Count Min	Excl Count Max	Excl Count Average	Excl Count Total	Incl Count Min	Incl Count Max	Incl Count Average	Incl Count Total
main()	1	-	-	170.00	170	-	-	1986.00	1986
sum1	1	690	690	690.00	690	690	690	690.00	690
sum2	1	616	616	616.00	616	616	616	616.00	616
sum3	1	340	340	340.00	340	340	340	340.00	340
sum4	1	170	170	170.00	170	170	170	170.00	170
Name	Calls	Excl Count Min	Excl Count Max	Excl Count Average	Excl Count Total	Incl Count Min	Incl Count Max	Incl Count Average	Incl Count Total
Name main()	Calls	Excl Count Min 70	Excl Count Max	Excl Count Average 70.00	Excl Count Total	Incl Count Min 1834	Incl Count Max 1834	Incl Count Average 1834.00	Incl Count Total
	Calls 1								
main()	Calls 1 1 1	70	70	70.00	70	1834	1834	1834.00	1834
main() sum1	Calls	70 653	70 653	70.00 653.00	70 653	1834 653	1834 653	1834.00 653.00	1834 653


Le mode Release est surtout utile pour le language C, en effet en assembleur c'est en quelque sorte à nous de faire l'optimisation.

II. Pipeline

L'optimisation par Pipeline est une approche qui permet de maximiser le travail des unités fonctionnels, en implémentant une bonne parrallélisation des tâches et en remplissant les délais. Il y a plusieurs étapes pour faire du pipeline :

- Ecrire le programme en C
- Ecrire le programme en assembleur linéaire
- Créer le graphe de dépendance
- Allouer de manière optimale les registres
- Ecrire la table de temps
- Programmer


Après avoir créer le programme en C et en assembleur, il est nécessaire de créer ce que l'on appelle un « graphe de dépendance ». J'ai décidé d'utiliser des *LDW* au lieu de *LDH* pour diminuer le temps de cycle. **Si l'on se concentre sur la boucle**, le graphe et l'allocation des registres sont de la forme suivante :




Register File A	#	#	Register File B
&x	A0	В0	&h
х	A1	B1	h
n	A2	B2	
	А3	В3	
sum[i]/y	A4	B4	sum[i+1]
prod[i]	A5	B5	prod[i+1]

On peut découper le programme en 3 séquences le prologue (initialisation nécessaire pour que la boucle fonctionne), la boucle principale et l'épilogue (qui évite de faire des instructions inutiles en trop comme des *LDH*).

La taille du prologue est determiné par la plus longue séquence d'instructions (ici LDW, MPY, ADD pour 7 cycles). L'épilogue revient à terminer les calculs sans faire des LDW en trop dans la boucle qui seraient inutiles. Il ne faut pas oublier de soustraire n pour avoir le bon nombre de boucles.





```
50 Loop:
                   LDW
                            .D1
                                    *A0++,A1 ; double { x[i+1], x[i] }
51
                   I DW
                            .D2
                                    *B0++,B1; double { h[i+1], h[i] }
           [A2]
52
                   SUB
                            .S1
                                    A2,2,A2
53
           [A2]
                            .S2
                                    Loop
                   MPY
54
                            .M1x
                                    A1,B1,A5; A5 = x[i]*h[i]
55
                   MPYH
                                    A1,B1,B5; B5 = x[i+1]*h[i+1]
                            .M2x
56
                                    A4,A5,A4; A4 = A4 + x[i]*h[i]
                   ADD
                            .L1
                   ADD
                            .L2
                                    B4,B5,B4; B4 = B4 + x[i+1]*h[i+1]
59 Epilog_1:
               MPY
                        .M1x
                                A1,B1,A5
                                             75 Epilog 4:
                                                            MPY
                                                                     .M1x
                                                                             A1,B1,A5
60
               MPYH
                        .M2x
                                A1,B1,B5
                                                            MPYH
                                                                     .M2x
                                                                             A1,B1,B5
                                             76
61
               ADD
                        .L1
                                A4,A5,A4
                                             77
                                                            ADD
                                                                     .L1
                                                                              A4,A5,A4
62
               ADD
                        .L2
                                B4,B5,B4
                                                            ADD
                                                                     .L2
                                                                             B4,B5,B4
                                             78
63
                                             79
               MPY
                                A1,B1,A5
64 Epilog_2:
                        .M1x
                                                                             A1,B1,A5
                                             80 Epilog 5:
                                                            MPY
                                                                     .M1x
65
               MPYH
                        .M2x
                                A1,B1,B5
                                             81
                                                            MPYH
                                                                     .M2x
                                                                             A1,B1,B5
66
               ADD
                        .L1
                                A4,A5,A4
                                                                             A4, A5, A4
                                             82
                                                            ADD
                                                                     .L1
67
               ADD
                        .L2
                                B4,B5,B4
                                             83
                                                            ADD
                                                                             B4,B5,B4
                                                                     .L2
68
```

Pour débuger, j'ai utilisé le « Memory browser » et les informations des registres. Ceci pour vérifier quand est-ce que les registres sont chargés et calculés pour chaque itération. Voici les résultats du profiler en mode debug :

84

86

87

89

90

85 Epilog_6:

88 Epilog_7:

91 Epilog_8:

ADD

ADD

ADD

ADD

ADD

.L1

.L2

.L1

.L2

.L1x

A4, A5, A4

B4, B5, B4

A4, A5, A4

B4,B5,B4

A4,B4,A4

1^{ère} fois

69 Epilog_3:

70

71

72

73

74

В

MPY

MPYH

ADD

ADD

.S2

.M1x

.M2x

.L1

.L2


В3

A1,B1,A5

A1,B1,B5

A4,A5,A4


B4,B5,B4



Name	Calls	Excl Count Min	Excl Count Max	Excl Count Average	Excl Count Total	Incl Count Min	Incl Count Max	Incl Count Average	Incl Count Total
main()	1	1466	1466	1466.00	1466	3262	3262	3262.00	3262
sum1	1	653	653	653.00	653	653	653	653.00	653
sum2	1	611	611	611.00	611	611	611	611.00	611
sum3	1	330	330	330.00	330	330	330	330.00	330
sum4	1	170	170	170.00	170	170	170	170.00	170
sum5	1	30	32	32.00	32	32	32	32.00	32

J'atteint un minimum de 30 boucles pour le calcul d'un produit scalaire, ce qui est un très bon résultat quand on compare au nombre de cycles en C du lab 2 (169 cycles de CPU en mode Release).

Release:



Pour conclure ces laboratoires, voici un petit schéma qui résume bien la programmation :



Ca a en effet été très rapide pour la programmation en C (quelques minutes) mais assez long pour l'optimisaton Pipeline qui nécessite beaucoup de rigueur (une à deux heures). A voir si les heures en plus sont justifiés par rapport au nombre de cycles.

Quelques minutes

169 cycles

1 à 2 heures → 30 cycles